

RELATÓRIO DE ANÁLISE ÉTICA EM INTELIGÊNCIA ARTIFICIAL

Deepfakes: transparência, riscos sociais e responsabilidade



Cleber Pavin

Bacharelado em Ciência da Computação

Disciplina: Design Profissional

Universidade Cruzeiro do Sul

Agosto de 2026

Experiência Prática III - Ética, cidadania digital e direitos

Resumo executivo

Este relatório analisa o dilema ético envolvendo o uso de deepfakes produzidos ou manipulados por Inteligência Artificial. O foco está nos casos em que vídeos, imagens ou áudios são usados para enganar pessoas, espalhar desinformação, aplicar golpes ou utilizar a imagem e a voz de alguém sem autorização. O tema foi escolhido por ser atual e por mostrar de forma clara que uma mesma tecnologia pode ter usos legítimos e, ao mesmo tempo, gerar danos relevantes quando não existem limites e mecanismos de segurança.

A análise foi organizada em quatro dimensões: viés e justiça, transparência, impactos sociais e governança. O resultado indica que a tecnologia não precisa ser banida, mas deve ser atualizada com restrições, identificação de conteúdo sintético, canais de denúncia, auditorias e controles contra falsificação de identidade. A legislação brasileira já oferece bases importantes para essa discussão, especialmente a LGPD, o Marco Civil da Internet e os Decretos nº 12.975/2026 e nº 12.976/2026. [1][2][3]

Método aplicado: identificação do problema, mapeamento das partes interessadas, avaliação de viés e justiça, análise de transparência e direitos, avaliação de impactos sociais e definição de governança e recomendações práticas.

1. Contexto e definição do dilema

Deepfakes são conteúdos sintéticos ou manipulados com técnicas de Inteligência Artificial para imitar pessoas, rostos ou vozes de forma convincente. A evolução dessas ferramentas diminuiu o custo e o conhecimento técnico necessários para criar conteúdos falsos, o que ampliou tanto os usos criativos quanto os riscos de fraude e desinformação. O FBI alerta que conteúdos sintéticos, incluindo clonagem de voz e vídeo, já são usados para se passar por pessoas conhecidas, funcionários e figuras públicas. [4][5]

O dilema ético não está simplesmente na existência da tecnologia. O problema aparece quando alguém usa um conteúdo artificial como se fosse verdadeiro, principalmente sem consentimento da pessoa representada. Nessa situação entram em conflito benefícios como criatividade, acessibilidade e produção audiovisual com direitos como privacidade, imagem, autonomia, segurança e proteção contra fraude.

Escolhi esse caso porque é fácil perceber como ele pode afetar pessoas comuns. Uma ligação com voz clonada, um vídeo falso ou uma imagem manipulada pode ser suficiente para convencer alguém a enviar dinheiro, compartilhar informações ou acreditar em uma acusação. Também é um tema que permite discutir claramente responsabilidade de usuários, empresas de IA, redes sociais e órgãos reguladores.

2. Escopo e partes interessadas

O escopo deste relatório está concentrado no uso de deepfakes para enganar, falsificar identidade, espalhar informação falsa ou utilizar imagem e voz sem autorização. Não são tratados como problema, por si só, usos claramente identificados em cinema, humor, arte, educação ou acessibilidade, desde que respeitem direitos e não tenham intenção de enganar.

Parte interessada	Risco principal	Necessidade
Pessoa representada	Pode ter imagem, voz, reputação ou privacidade afetadas.	Consentimento e meios rápidos de contestação.
Usuários e público	Podem acreditar em conteúdo falso e tomar decisões erradas.	Avisos claros, educação digital e ferramentas de verificação.
Empresas de IA	Criam ou disponibilizam ferramentas capazes de gerar conteúdo sintético.	Segurança por design, restrições de abuso, rastreabilidade e auditoria.
Plataformas digitais	Podem ampliar rapidamente o alcance de conteúdos manipulados.	Denúncia acessível, moderação, redução de alcance e remoção nos casos previstos.
Empresas e empregadores	Podem sofrer fraude financeira, falsificação de ordens ou dano reputacional.	Procedimentos de verificação e treinamento de equipes.
Poder público e reguladores	Definem regras e fiscalizam deveres relacionados a dados e plataformas.	Normas claras, fiscalização e atualização regulatória.

3. Avaliação de viés e justiça

No caso dos deepfakes, o viés pode aparecer em mais de uma etapa. Primeiro, os modelos de geração e de detecção dependem dos dados utilizados no treinamento. Se determinados grupos estiverem pouco representados ou aparecerem de forma desequilibrada, o desempenho pode variar entre idades, gêneros ou outros grupos. Estudos recentes sobre detecção de deepfakes mostram que justiça demográfica e generalização ainda são desafios técnicos, o que significa que um detector pode funcionar melhor para algumas pessoas do que para outras. [6][7]

Existe também uma desigualdade na distribuição dos danos. Uma pessoa que tem a imagem ou a voz usada em um conteúdo falso pode sofrer consequências que não atingem quem apenas utiliza a ferramenta para entretenimento. No Brasil, a preocupação com esse tipo de dano levou a regras específicas em 2026 para enfrentar violência digital contra mulheres, incluindo a obrigação de plataformas adotarem salvaguardas contra geração ou modificação de conteúdo íntimo por IA nos casos abrangidos pelo Decreto nº 12.976/2026. [2]

Por isso, justiça nesse caso não significa somente melhorar a precisão do algoritmo. Também significa garantir que os riscos não sejam simplesmente transferidos para a vítima. Quem é representado sem consentimento precisa ter meios de denúncia, contestação e retirada do conteúdo, enquanto empresas e plataformas precisam assumir parte da prevenção.

4. Transparência e explicabilidade

Em deepfakes, a falta de transparência aparece principalmente quando o usuário não consegue saber se um conteúdo foi criado ou alterado por IA, qual ferramenta foi usada e se a pessoa representada autorizou aquele uso. Diferente de um sistema que aprova ou rejeita uma candidatura, aqui o problema da caixa-preta está muito ligado à origem e à autenticidade do conteúdo.

A transparência pode ser melhorada com identificação visível de conteúdo sintético, metadados de procedência, registros de criação e mecanismos que permitam verificar a origem

de um arquivo. Nenhuma dessas medidas é perfeita isoladamente, porque marcas podem ser removidas e arquivos podem ser recodificados. Mesmo assim, combinar identificação, rastreabilidade e verificação reduz a chance de um conteúdo manipulado circular sem nenhum sinal de alerta.

A falta de explicabilidade também afeta a autonomia. Se uma pessoa toma uma decisão acreditando que um vídeo ou áudio é verdadeiro, mas ele foi fabricado, sua escolha foi influenciada por uma informação falsa. A UNESCO vem destacando que a IA generativa e os deepfakes ampliam riscos de desinformação e tornam mais difícil distinguir conteúdos confiáveis de conteúdos manipulados. [8]

5. Impactos sociais, mercado de trabalho e direitos

Os impactos sociais dos deepfakes não ficam restritos às redes sociais. Eles podem atingir relações pessoais, reputação, empresas e decisões financeiras. Em ambiente profissional, uma voz clonada pode fingir ser um gestor solicitando uma transferência ou um vídeo falso pode ser usado para atacar a imagem de um funcionário ou candidato. O FBI registrou, em 2025, 22.364 reclamações relacionadas ao uso de IA em crimes e fraudes, com perdas ajustadas superiores a US\$ 893 milhões. O relatório cita voz clonada, perfis falsos e vídeos convincentes como recursos usados por golpistas. [5]

Na proteção de dados, a LGPD define dado pessoal como informação relacionada a pessoa natural identificada ou identificável. A ANPD também explica que aparência e outras informações associáveis a uma pessoa podem ser dados pessoais. Por isso, dependendo do caso, o uso de imagem, voz e outros elementos para criar uma representação falsa pode envolver tratamento de dados sujeito às regras da LGPD. [1][9]

Os princípios da LGPD que mais se relacionam a esse caso são finalidade, necessidade, transparência, segurança, prevenção, não discriminação e responsabilização. Isso reforça uma ideia simples: não basta uma empresa conseguir tecnicamente usar determinado dado; ela precisa justificar o tratamento, limitar o uso ao necessário, proteger o titular e demonstrar as medidas tomadas para evitar danos. [1]

6. Responsabilidade, governança e legislação aplicável

A responsabilidade precisa ser distribuída. Quem cria deliberadamente um deepfake para aplicar golpe ou atacar alguém tem responsabilidade direta pelo uso. Porém, isso não elimina o dever das empresas que desenvolvem as ferramentas e das plataformas que distribuem o conteúdo de adotar medidas proporcionais aos riscos que conseguem prever e controlar.

No Brasil, a LGPD oferece a base de proteção de dados e estabelece princípios de prevenção, segurança, transparência e prestação de contas. O Marco Civil da Internet também integra esse cenário. Em 2026, os Decretos nº 12.975 e nº 12.976 reforçaram deveres de plataformas digitais relacionados à prevenção e mitigação de riscos, enfrentamento de fraudes e golpes, canais de denúncia e proteção de mulheres contra violência digital. A ANPD passou a monitorar esses deveres e incluiu deepfakes em sua agenda tecnológica. [2][3]

É importante não transformar essas regras em uma afirmação de que todo deepfake é proibido. A regulação é mais específica: existem deveres diferentes conforme o tipo de conteúdo, o dano envolvido e o papel da plataforma. No caso de conteúdo íntimo manipulado

por IA contra mulheres, o Decreto nº 12.976/2026 trouxe obrigações próprias, inclusive salvaguardas técnicas para identificar e bloquear determinadas solicitações e retirada rápida de conteúdo não autorizado após notificação. [2]

7. Síntese do framework ético

Dimensão	Problema identificado	Resposta proposta
Viés e justiça	Desempenho desigual de detectores e danos concentrados em vítimas específicas.	Dados mais representativos, testes por grupos e processo de contestação.
Transparência	Usuário pode não saber que o conteúdo é sintético nem sua origem.	Rótulo claro, metadados de procedência e rastreabilidade.
Impacto social	Fraude, desinformação, dano reputacional e perda de autonomia.	Verificação, educação digital e resposta rápida a abuso.
Governança	Responsabilidade pode ficar dispersa entre criador, ferramenta e plataforma.	Políticas de uso, auditoria, canais de denúncia e registro de incidentes.
Proteção de dados	Imagem, voz e outros dados podem ser tratados sem base adequada.	Aplicar LGPD, minimizar dados e documentar finalidade e medidas de segurança.

8. Posicionamento profissional e recomendações

A tecnologia de deepfake não deve ser banida de forma geral, mas precisa ser atualizada com restrições e mecanismos de segurança. Existem usos legítimos em entretenimento, educação, acessibilidade e produção audiovisual. O problema aparece quando a ferramenta é utilizada para enganar, falsificar identidade, espalhar informação falsa ou usar a imagem e a voz de outra pessoa de forma abusiva.

1. Identificação e procedência do conteúdo: Conteúdos criados ou alterados de forma relevante por IA devem trazer identificação clara e, quando tecnicamente possível, informações de procedência que ajudem a verificar sua origem. A medida não elimina a fraude, mas aumenta a transparência e ajuda usuários e plataformas a desconfiar de conteúdos manipulados.

2. Restrições de segurança contra abuso: Ferramentas de geração devem bloquear ou limitar solicitações claramente voltadas a falsificação de identidade, conteúdo íntimo não consentido, golpes e outras formas previsíveis de dano. Também devem existir mecanismos para registrar abuso e melhorar continuamente os filtros.

3. Denúncia e resposta rápida: Plataformas precisam oferecer um canal simples para a pessoa afetada contestar um conteúdo, pedir análise e acompanhar a resposta. Casos de maior risco devem receber prioridade, seguindo as obrigações legais aplicáveis.

4. Auditoria e testes periódicos: Modelos de geração, moderação e detecção devem ser avaliados regularmente. Os testes precisam verificar precisão, falsos positivos, falsos negativos, diferenças entre grupos e capacidade de funcionar diante de novas técnicas de manipulação.

5. Educação digital e verificação interna: Empresas e usuários devem ser orientados a verificar pedidos sensíveis por outro canal. Em situações financeiras ou profissionais, não é seguro confiar apenas em áudio, vídeo ou mensagem recebida, mesmo quando parece vir de alguém conhecido.

9. Conclusão

A análise mostra que o maior desafio dos deepfakes não é apenas técnico. Mesmo que os modelos fiquem mais avançados, continuará existindo uma questão de responsabilidade sobre como a tecnologia é criada, disponibilizada e utilizada. O risco aumenta quando um conteúdo falso parece verdadeiro, circula rapidamente e a vítima não consegue identificar a origem nem remover o material com facilidade.

A solução mais equilibrada é permitir os usos legítimos, mas exigir mais transparência, proteção de dados, prevenção e responsabilização. Para mim, a ideia de Ethical AI by Design faz sentido justamente por isso: pensar no dano antes de liberar uma ferramenta é mais eficiente do que tentar resolver tudo somente depois que alguém já foi prejudicado.

Como estudante de Ciência da Computação, este caso também deixou claro que desenvolver tecnologia envolve decisões que vão além de fazer um sistema funcionar. É preciso pensar em quem pode ser afetado, quais riscos podem surgir e quais controles precisam existir para que a solução seja usada de forma responsável.

Referências

- [1] BRASIL. Lei nº 13.709/2018 - Lei Geral de Proteção de Dados Pessoais (LGPD). Planalto. [Acesso à fonte](#)
- [2] AGÊNCIA NACIONAL DE PROTEÇÃO DE DADOS (ANPD). Marco Civil da Internet: novas obrigações para plataformas digitais e proteção contra deepfakes. 2026. [Acesso à fonte](#)
- [3] AGÊNCIA NACIONAL DE PROTEÇÃO DE DADOS (ANPD). Nota sobre os Decretos nº 12.975/2026 e nº 12.976/2026. 21 maio 2026. [Acesso à fonte](#)
- [4] FEDERAL BUREAU OF INVESTIGATION (FBI). Artificial Intelligence: synthetic content and deepfakes. [Acesso à fonte](#)
- [5] FEDERAL BUREAU OF INVESTIGATION (FBI). 2025 IC3 Annual Report: Artificial Intelligence Used in Cybercrime. 2026. [Acesso à fonte](#)
- [6] EZEAKUNNE, U.; EZE, C.; LIU, X. Data-Driven Fairness Generalization for Deepfake Detection. 2024. [Acesso à fonte](#)
- [7] JOSHI, U. Age-Diverse Deepfake Dataset: Bridging the Age Gap in Deepfake Detection. 2025. [Acesso à fonte](#)
- [8] UNESCO. Inteligencia artificial y desinformación. 11 mar. 2026. [Acesso à fonte](#)
- [9] AGÊNCIA NACIONAL DE PROTEÇÃO DE DADOS (ANPD). Titular de Dados: conceito de dado pessoal. [Acesso à fonte](#)
- [10] AGÊNCIA NACIONAL DE PROTEÇÃO DE DADOS (ANPD). Radar Tecnológico nº 6 - Deepfakes. 28 jul. 2026. [Acesso à fonte](#)

Fontes consultadas em agosto de 2026. O relatório apresenta uma análise acadêmica e não substitui orientação jurídica.